

NGUYỄN LÊ QUỐC BẢO

Kỹ sư AI · LLM Agent · Computer Vision · AI tạo sinh

Việt Nam · 0326 032 296 · ngbao3558@gmail.com
GitHub: github.com/baonguyen3568 · Portfolio: baonguyen3568.github.io/myprofile

GIỚI THIỆU

Kỹ sư AI với 14 tháng làm sản phẩm thực tế về LLM agent, computer vision thời gian thực và AI tạo sinh, triển khai trên hạ tầng NVIDIA do chính mình vận hành. Phụ trách backend chính và toàn bộ việc phát hành của một nền tảng bán hàng AI, ra 14 phiên bản trong ba tuần. Một mình xây dựng hệ thống chấm công bằng nhận diện khuôn mặt, chạy production từ tháng 4/2026 tại hai chi nhánh. Làm xuyên suốt từ dựng máy GPU, chạy model local đến thiết kế agent, quyết định sản phẩm và demo cho khách hàng.

KINH NGHIỆM LÀM VIỆC

Kỹ sư AI kiêm Product Manager — Tin học Viễn thông Nhất Tiến Chung (NTC) 09/2025 – nay

Nhóm giải pháp AI phục vụ NTC và các công ty liên kết (Thế Giới Máy Chủ, NTC AI). Dẫn dắt nhóm dự án tối đa 5 người, chịu trách nhiệm kiến trúc, phân công công việc và phát hành.

NTCsale — Trợ lý bán hàng AI & nền tảng tạo website bán hàng · SaaS đa tenant 08/2026 – nay
saleai.ntc.ai.vn

- Phụ trách backend chính trong nhóm 5 người (2 backend, 1 frontend, 2 tester) và trực tiếp đưa mọi bản phát hành lên production: **14 phiên bản trong 3 tuần**. Tự dựng nền tảng backend, xác thực và tính năng tạo website bằng AI trên FastAPI, PostgreSQL, Redis, MinIO và Next.js.
- Hai lần refactor codebase sang **modular monolith theo mô hình ports-and-adapters**, có công cụ tự động kiểm tra vi phạm kiến trúc. Đặt ra cách quản lý cấu hình chung cho cả nhóm (DB/admin, biến môi trường, kho prompt có phiên bản).
- Thiết kế **quy trình phát triển đa agent** cho nhóm: 12 coding agent theo vai trò (research, bảo mật, kiểm thử, sửa lỗi, thiết kế) dùng chung quy tắc, skill và memory, phối hợp qua GitHub issue bằng MCP, còn quyết định kiến trúc thì chuyển lên cho tôi chốt. Nhóm đã merge **686 PR** và đóng **844 issue** trong khoảng bốn tuần.
- Chuyển trợ lý bán hàng từ kiến trúc planner–executor về **một vòng lặp tool-calling duy nhất** khi planner chạy không ổn định trên model 27B tự host. Sắp xếp lại context theo memory phân tầng và trả lỗi tool có cấu trúc về cho model để nó tự xử lý tiếp, thay vì rơi về câu trả lời soạn sẵn.
- Giới hạn LLM của trình tạo website chỉ sinh nội dung và bảng màu trên template cố định. Batch nào bị cắt cụt sẽ được chia đôi để chạy lại, slot nào lỗi thì giữ nội dung mẫu, nhờ vậy chi phí token mỗi lần tạo luôn có mức trần.
- Xử lý sự cố production (header CSP 5.762 byte vượt giới hạn 4.096 byte của Nginx): rollback trong chưa đầy 17 phút, ra bản sửa sau 27 phút và thêm bước kiểm tra để policy quá cỡ bị chặn ngay lúc build thay vì lúc deploy.
- Đang chạy thử tại một công ty liên kết: chatbot trên website và quản lý khoảng 1.600 sản phẩm.

NTC VisionID — Chấm công bằng nhận diện khuôn mặt · edge AI thời gian thực 04/2026 – nay
vision.ntc.ai.vn

- **Một mình làm từ thiết kế đến production** (có thêm một người cùng bảo trì từ 10/2026): 3 công ty liên kết, **9 camera RTSP** tại TP.HCM và Hà Nội, khoảng **60 nhân viên** chấm công mỗi ngày.
- Xây pipeline GStreamer → phát hiện khuôn mặt SCRFD → trích xuất embedding ArcFace → tracking, đạt **15–20 FPS mỗi camera** khi có 20–30 người trong khung hình trên một GPU RTX PRO 2000 Blackwell. Đã chuyển hệ thống qua lại giữa Jetson, RTX PRO 5000 và RTX PRO 2000.
- Tinh chỉnh ngưỡng nhận diện cosine từ 0.70 xuống 0.55 dựa trên phản hồi thực tế, hết tình trạng chấm công chậm và đến nay chưa ghi nhận trường hợp nhận nhầm. Thay thông báo email/Telegram hay bị trễ bằng PWA có web push.
- Xây thêm toàn bộ phần nghiệp vụ nhân sự: quy tắc ca làm, đơn nghỉ phép, giải trình chấm công, tăng ca, duyệt nhiều cấp, phân quyền theo vai trò và xuất dữ liệu tính lương.

blog2vid — Sản xuất video bằng AI chạy hoàn toàn local · đang phát triển 10/2026 – nay

- Dẫn dắt 7 agent xây pipeline biến bài viết thành video trên DGX Spark: Qwen3.8-27B viết kịch bản → Qwen-Image-Edit tạo ảnh → **MiniMax H3** dựng video kèm âm thanh → VieNeu-TTS clone giọng → ACE-Step làm nhạc nền → HyperFrames ghép thành phẩm. Backend dùng FastAPI, MongoDB, Redis và Kafka.
- Chọn model dựa trên benchmark công khai và rà soát giấy phép (loại LTX vì license, chuyển từ Wan 2.2 sang H3). Gia cố máy dùng chung bằng cơ chế chống OOM, giới hạn 50% bộ nhớ và watchdog nhiệt độ sau những lần treo máy ở 97 °C.

Hạ tầng AI, PoC & hỗ trợ kinh doanh 09/2025 – nay

- Dựng và vận hành nhiều dòng thiết bị NVIDIA từ khâu cài hệ điều hành: DGX Spark (GB10), máy chủ RTX PRO 5000/2000 Blackwell, thiết bị edge Jetson và VPS Xeon Gold. Chạy LLM local bằng vLLM (Qwen3.8-27B NVFP4, KV cache FP8) cho sản phẩm nội bộ và PoC khách hàng.
- Xây ứng dụng **Document Agent RAG** trên labs.ntc.ai.vn, kho ứng dụng để khách hàng tự cài lên DGX Spark chỉ bằng một lệnh. Hệ thống đọc tài liệu bằng OCR và model thị giác, tìm kiếm hybrid lexical + vector trên OpenSearch, rerank, rồi để agent tool-calling trả lời kèm nguồn file và trang. Phân công team đóng gói các blueprint NVIDIA lên cùng kho này để hỗ trợ bán GB10.
- Đại diện NTC tại **DCCI Summit 2026** (Viettel IDC, TP.HCM — camera AI chạy trên Jetson), **AI Day 2026** (Hà Nội — runtime agent NemoClaw/Hermes và agentic coding) và một sự kiện đối tác của **TD SYNNEX** (TP.HCM — trợ lý RAG cho ngân hàng): thuyết trình, demo tại booth và tư vấn giải pháp cho khách hàng.
- Viết nội dung kỹ thuật và đề xuất giải pháp, gồm bài viết về NVIDIA Vera Rubin tại OCP 2026 và đề xuất NVIDIA AI Factory Operations Agent cho khách hàng doanh nghiệp.

KỸ NĂNG CHUYÊN MÔN

LLM & agent	Tool-calling agent, LangGraph, LangChain, context engineering, memory phân tầng, MCP, agentic RAG, hybrid retrieval (OpenSearch, Qdrant), rerank, Docling, structured output, gateway tương thích OpenAI/Anthropic, runtime NemoClaw/Hermes, quy trình coding đa agent
Model serving	vLLM, suy luận lượng tử hoá NVFP4/FP8, DGX Spark (GB10), RTX PRO Blackwell, Jetson, CUDA, tối ưu bộ nhớ và nhiệt độ GPU
Computer vision	InsightFace (SCRFD, ArcFace), GStreamer, RTSP, tracking đa camera, vector search, tinh chỉnh ngưỡng nhận diện
AI tạo sinh	MiniMax H3, Wan 2.2, Qwen-Image-Edit, ComfyUI, VieNeu-TTS (clone giọng), ACE-Step, NVIDIA Riva
Backend & nền tảng	Python, FastAPI, SQLAlchemy/asyncpg, PostgreSQL, MongoDB, Redis, Kafka, MinIO/S3, Nginx, Docker Compose, TypeScript, Next.js, React
Quy trình kỹ thuật	Modular monolith / ports and adapters, ADR (architecture decision record), CI/CD và quản lý phát hành, xử lý sự cố, review code

HỌC VẤN

Kỹ sư Trí tuệ nhân tạo — Trường Đại học Nguyễn Tất Thành 2021 – 2025
GPA 3.32 / 4.00 · Xếp loại: Giỏi

NGOẠI NGỮ

Tiếng Việt (bản ngữ) · Tiếng Anh (đọc hiểu tốt tài liệu kỹ thuật chuyên ngành)